



Universidad Autónoma de Occidente
Facultad de ingeniería y Ciencias Básicas
ETL

Avance 1 (Contexto y Problema) – versión ajustada según retroalimentación

Nombres: Simon Colonia Amador, Ingrid Valentina, Willy Daniel

1. Contexto (Describir el contexto donde ocurre la necesidad o problema identificado)

En Colombia, el servicio de energía eléctrica se presta bajo dos esquemas: el Sistema Interconectado Nacional (SIN), que cubre la mayoría del territorio, y las Zonas No Interconectadas (ZNI), definidas por la Ley 855 de 2003 como los municipios, corregimientos, localidades y caseríos que no están conectados a la red nacional (departamentos como Amazonas, Chocó, Guainía, Vaupés, Vichada y el Archipiélago de San Andrés, entre otros).

En las ZNI el servicio lo prestan operadores locales (empresas, cooperativas o alcaldías) con plantas diésel, pequeñas centrales hidroeléctricas o sistemas solares, articulados por el IPSE (Instituto de Planificación y Promoción de Soluciones Energéticas) y financiados en parte con recursos del FAZNI. La continuidad y calidad de este servicio es mucho más baja y variable que en el SIN: muchas localidades reciben solo algunas horas de energía al día.

El Ministerio de Minas y Energía publica en datos.gov.co el dataset "Estado de la prestación del servicio de energía en Zonas No Interconectadas" (id 3ebi-d83g), que reúne los reportes de los operadores por localidad. Sin embargo, esta información llega de forma dispersa, en formatos y periodicidades distintas, lo que dificulta consolidarla para el seguimiento y la toma de decisiones. En este contexto surge la necesidad de un pipeline ETL que integre, limpie y estandarice estos datos en un modelo analítico único y actualizado. El presente trabajo pondrá especial foco en los departamentos del suroccidente colombiano (Valle del Cauca, Cauca, Nariño y Putumayo) como caso de estudio dentro del panorama nacional de ZNI.

2. Caracterización del usuario (Descripción o perfil del usuario/cliente)

Usuario primario: analista de política energética (Ministerio de Minas y Energía / IPSE)

- Perfil: profesional de ingeniería, economía o afines, con conocimiento del sector eléctrico pero sin necesariamente competencias técnicas de programación o manejo de bases de datos.
- Necesidad: contar con indicadores consolidados, actualizados y comparables (por localidad, departamento y operador) para priorizar inversión del FAZNI, hacer seguimiento a metas de cobertura y responder a entes de control.
- Uso esperado: tableros de control (dashboards) y reportes periódicos, no acceso directo a datos crudos.

Usuarios secundarios

- Operadores locales de energía: reportan los datos de origen y podrían usar el pipeline para comparar su desempeño con el de otros operadores.
- Gobiernos municipales y comunidades de las ZNI: interesados en visibilizar el estado del servicio en su territorio para sustentar solicitudes de inversión.

4. Fuentes de datos: Relacionar preliminarmente posibles fuentes de datos:

Se mantiene como fuente principal el dataset oficial ya referenciado en el contexto (id 3ebi-d83g), y se complementa con dos fuentes del mismo portal que cubren sus vacíos (identidad del operador y calidad percibida por el usuario):

Fuente	Sistema	Tipo	Frecuencia	Dueño	Calidad
Estado de la prestación del servicio de energía en ZNI (id 3ebi-d83g) — FUENTE PRIMARIA	Portal de Datos Abiertos Colombia (Socrata): API SoQL, CSV, JSON	Datos operativos agregados por localidad: energía activa/reactiva, potencia máxima, horas de servicio	Mensual (activa; última actualización ene-2026)	Ministerio de Minas y Energía / IPSE	Alta
Registro de Operación Diario ZNI (id qwe5-ycap) — complementaria	Portal de Datos Abiertos Colombia (Socrata): API/CSV	Bitácora diaria de generación por localidad y operador (~455 mil registros; incluye nombre de operador y capacidad)	Semestral nominal, sin actualizar desde jun-2023	Superintendencia de Servicios Públicos (Superservicios)	Media
Reclamaciones y Quejas – Informe PQR (id 5wua-nr2d) — complementaria	Portal de Datos Abiertos Colombia (Socrata): API/CSV	Registro de peticiones, quejas y reclamos por empresa y municipio	Semestral (última actualización mar-2024)	Superintendencia de Servicios Públicos (Superservicios)	Media

3ebi-d83g se usa como fuente principal porque es oficial y se actualiza mensualmente. Las otras dos vienen de Superservicios y completan lo que a esa fuente le falta: qwe5-ycap identifica qué operador presta el servicio en cada localidad, y 5wua-nr2d muestra las quejas radicadas por esos operadores. Como cada entidad escribe los nombres de departamento y municipio de forma distinta, el cruce entre las tres se hace por código DANE y no por el nombre en texto: por localidad entre 3ebi-d83g y qwe5-ycap, y por municipio para 5wua-nr2d (ver 4.1).

4.1 Matriz de granularidad y llaves

Antes de cualquier unión se documenta la granularidad de cada fuente y la llave con la que puede relacionarse. Las llaves se definen a partir de la descripción de cada fuente; una llave solo se declara válida si supera las pruebas de validación de esta sección, y ninguna unión se construye antes de eso.

Fuente	Granularidad	Llave candidata	Periodicidad y corte	Rol en el modelo	Unión permitida
3ebi-d83g	Localidad × mes	Código DANE de localidad + periodo (mes)	Mensual; última actualización ene-2026	Tabla de hechos: energía activa/reactiva, potencia máxima y horas de servicio	Base del modelo

qwe5-ycap	Localidad × día × operador	Código DANE de localidad + fecha + operador	Sin actualizar desde jun-2023	Relación operador–localidad (vigente hasta jun-2023)	A 3ebi-d83g por localidad, agregando antes de diario a mensual
5wua-nr2d	Empresa × municipio × semestre	Código DANE de municipio + empresa + semestre	Última actualización mar-2024	Tabla de hechos de PQR	Solo a nivel de municipio; el vínculo con el operador se valida por identificador de empresa. No se asigna a una localidad individual

Uniones permitidas

Unión	Nivel	Tipo de unión	Cardinalidad esperada	Condición
Prestación (3ebi-d83g) ↔ Operador (qwe5-ycap)	Localidad + mes	LEFT JOIN desde 3ebi-d83g, con qwe5-ycap agregado antes a localidad-mes	N:1 (validar si una localidad tiene más de un operador en el mismo mes)	Solo hasta jun-2023; después el operador se marca "sin dato vigente"
Prestación (3ebi-d83g) ↔ PQR (5wua-nr2d)	Municipio + semestre	LEFT JOIN de 3ebi-d83g (cada mes asignado a su semestre) hacia PQR agregada por municipio-semestre	N:1 (varias localidades comparten las PQR de su municipio)	Solo hasta mar-2024; la PQR no se reparte ni se asigna a una localidad
Operador (qwe5-ycap) ↔ PQR (5wua-nr2d)	Municipio + empresa	LEFT JOIN desde el par operador–municipio hacia PQR por identificador de empresa	N:1 (validar); depende de que ambas fuentes compartan identificador de empresa	Si no hay identificador común, la unión se limita al municipio

Uniones no permitidas

- 5wua-nr2d a nivel de localidad: la fuente llega solo hasta empresa-municipio y asignarla a una localidad crearía una precisión que el dato no tiene.
- Cualquier unión por nombre de departamento, municipio o localidad en texto libre.

Reglas de unión

- Los códigos DANE se almacenan como texto con ceros a la izquierda (5 dígitos para municipio y 8 para localidad o centro poblado, según DIVIPOLA; se confirma en el perfilado).
- Las PQR se agregan por municipio y semestre antes de la unión, para no duplicar filas de las tablas por localidad.
- Los meses de 3ebi-d83g se asignan al semestre que les corresponde (ene-jun y jul-dic) antes de unirse con PQR.
- De cada unión se documenta la cardinalidad observada (1:1, 1:N o N:M) y el porcentaje de llaves sin cruce.

Validación de llaves previa a las uniones

Prueba	Criterio de aceptación	Relación
Unicidad de la llave de cada fuente	0 duplicados en la llave candidata; si los hay, se documentan y se tratan antes de unir	KR2
Validez del código DANE	≥ 95 % de códigos válidos frente al catálogo DIVIPOLA del DANE	KR2
Cruce entre fuentes	Porcentaje de llaves sin cruce documentado para cada unión	KR2
Identificador de empresa común (qwe5-ycap y 5wua-nr2d)	Existe un identificador presente en ambas fuentes y coincide en ≥ 95 % de las empresas; si no, la relación operador–PQR se limita al municipio	KR2
Cardinalidad	Cardinalidad observada registrada por unión y comparada con la esperada	Matriz 4.1

Regla de bloqueo: las pruebas se ejecutan en el perfilado de las tres fuentes (28-sep a 2-oct-2026), con el nombre real de cada campo, y sus resultados se registran en esta matriz antes de construir cualquier unión. Una unión que no supere las pruebas no se implementa.

4.2 Política de frescura de los datos

Cada fuente conserva su fecha de corte y el modelo solo compara periodos en los que las fuentes son comparables.

Estado	Criterio	Tratamiento en el tablero
Vigente	Última actualización dentro de 2 periodos de su frecuencia	Sin advertencia
Desactualizada	Más de 2 periodos de retraso	Etiqueta "dato no actualizado" con la fecha de corte
Congelada	Sin actualización nominal (qwe5-ycap: jun-2023; 5wua-nr2d: mar-2024)	Se compara solo dentro de su ventana de vigencia; fuera de ella se marca "periodo no comparable"

Aplicación de la regla a las tres fuentes

Fuente	Última actualización registrada	Estado según la regla
3ebi-d83g	ene-2026 (según la tabla de fuentes)	Se reverifica en el perfilado; si no hay cortes posteriores y supera 2 periodos de retraso, pasa a "Desactualizada"
qwe5-ycap	jun-2023	Congelada
5wua-nr2d	mar-2024	Congelada

- Cada registro lleva la fecha de corte de su fuente y un indicador de comparabilidad.
- Los cruces operador–localidad posteriores a jun-2023 y las PQR posteriores a mar-2024 se muestran con advertencia y no como dato vigente.

4.3 Herramientas del pipeline

Etapas	Herramienta	Uso en el proyecto
Extracción	Socrata API (SoQL)	Consulta paginada de los tres conjuntos de datos con filtros por departamento y código DANE, en formato JSON o CSV
Transformación	Python y Pandas	Limpieza, estandarización de códigos DANE, eliminación de duplicados, agregación por localidad-mes y municipio-semestre, y reglas de calidad

Almacenamiento	PostgreSQL	Modelo analítico con la dimensión de localidad y las tablas de hechos de prestación y de PQR (se selecciona PostgreSQL; MySQL es la alternativa)
Visualización	Power BI	Tablero del MVP con indicadores por localidad, departamento y operador, y advertencias de frescura

5. OKR y KPIS

OKR

Objetivo: Disponer, al 9 de octubre de 2026, de un modelo analítico único, trazable y reproducible sobre la prestación del servicio de energía en las ZNI de Valle del Cauca, Cauca, Nariño y Putumayo, para que los analistas de política energética consulten indicadores confiables.

Resultados clave

KR	Resultado clave	Meta	Fecha
KR1	Fuentes integradas en PostgreSQL con carga automatizada (3ebi-d83g, qwe5-ycap y 5wua-nr2d)	3 de 3 fuentes	5-oct-2026
KR2	Registros con código DANE válido y cruce exitoso; registros duplicados; campos críticos completos	≥ 95 %; ≤ 1 %; ≥ 98 %	7-oct-2026
KR3	Registros con trazabilidad (fuente, fecha de carga y regla aplicada) y pipeline reproducible de principio a fin con un solo comando	100 % con trazabilidad; 0 errores de transformación sin controlar	8-oct-2026
KR4	Tablero en Power BI con los indicadores del MVP para los 4 departamentos, con advertencia de frescura por fuente	1 tablero publicado	9-oct-2026

KPIS

KPIs del MVP (miden los KR)

- KR1: % de fuentes integradas; % de indicadores con fuente identificada.
- KR2: % de variables estandarizadas; % de registros duplicados; % de campos críticos completos.
- KR3: % de registros con trazabilidad; % de información reproducible; número de errores de transformación; % de reglas de negocio documentadas.
- KR4: % de disponibilidad del pipeline; % de localidades con servicio.

KPIs de fase 2 (dependen de fuentes adicionales: población, costos, proyectos FAZNI históricos y universo de localidades)

- % de municipios atendidos.
- % de población atendida.
- Inversión potencial por localidad.
- Inversión potencial por departamento.
- Evolución del índice de prioridad.

6. Posibles preguntas estratégicas o de negocio a responder con el Pipeline ETL.

6.1 Preguntas del MVP (responsibles con prestación, operador y PQR)

1. ¿Cuál es el estado actual de la prestación de servicio eléctrico en ZNI para la región Suroccidente del país (localidades con servicio, horas de servicio, energía activa y potencia máxima)?
2. ¿Qué departamentos y municipios concentran las mayores brechas en la prestación del servicio, medidas en horas de servicio?
3. ¿Cómo ha evolucionado la prestación del servicio en los departamentos del suroccidente colombiano (Valle del Cauca, Cauca, Nariño y Putumayo) en los últimos años?
4. ¿Qué operador presta el servicio en cada localidad del suroccidente y cómo se comparan las horas de servicio entre operadores? (registro de operador vigente hasta jun-2023)
5. ¿Qué empresas y municipios concentran más PQR y cómo se comparan con las horas de servicio de su municipio? (análisis a nivel de municipio)
6. ¿Qué municipios presentan el peor desempeño combinado (horas de servicio y PQR) y cuáles de sus localidades tienen menos horas de servicio?

6.2 Preguntas de una fase posterior (requieren fuentes adicionales)

Pregunta	Fuentes adicionales necesarias (candidatas)
¿De qué manera se deberían apoyar los proyectos de fuentes renovables que el país busca adoptar en su modelo de energización, para impactar al mayor número de personas en una comunidad?	Población por localidad (DANE), proyectos FAZNI históricos, recursos renovables disponibles y costos
¿Qué tipo de generadores deberían implementarse en las ZNI, según los consumos identificados y las fuentes disponibles?	Recursos renovables (atlas solar y eólico UPME–IDEAM), capacidad instalada vigente por tecnología (IPSE/SUI; qwe5-ycap solo la reporta hasta jun-2023) y costos de generación
¿Cuáles comunidades del suroccidente colombiano nunca han recibido atención de estos programas?	Universo completo de localidades ZNI (DIVIPOLA) y proyectos FAZNI/IPSE históricos
¿Dónde es más rentable invertir (inversión óptima y prioridad de inversión por localidad)?	Población, costos unitarios y proyectos históricos
¿Qué nivel de cumplimiento presentan las ZNI frente a las metas o estándares definidos para cobertura y prestación del servicio?	Metas y estándares oficiales de cobertura y horas de servicio (normativa y planes sectoriales de MinEnergía e IPSE)

La disponibilidad y la granularidad de estas fuentes se evaluarán antes de incluirlas en el pipeline.